MiniProject 2

Details are now available:

• Due 22 juillet à 23h55.

ULaval IPT&GLO

Mini-Projet #2 (sur 20%)
a rendm le 22 juillet 2000 à 23855mn

Professeur Brakim Chails-dras GLO-7050 : Apprentissage machine en pratique

Les projets du cours sont les projets des versions du cours COMP 551, cours donné par les collègues de McGill, un grand merci à eux pour nous avoir donné l'autorisation de les utilises.

Preamble

- Ce mini-projet constitue un travail individuel. Toutefois, ceci nous vous empêche pas de discuter avec les autres étudiants qui suivent le cours. En aucun cas cependant vous ne devez reprendre le code et l'écrit d'autrui; il vous est demande d'élaborer les vôtres.
- Vous alles soumettre votre travail sur MonFortail, et également à une compétition Kaggle. Vous deux ous innaire pour la compétition Kaggle en utilisant le courriel auquel vous êtres associé sur MonFortail (c-±d. Oulaval.a). Vous pouvez vous inscrire à la compétition à l'advense suivante: https://www.kaggle.com/d-habifétédai/24aa69479659551123. Pour le MiniProject 2, vous devue enregitere votre Equipe indriduelle (un étudiant par équipe) sur MonFortail. Vous devue ne suitere votre l'expire indriduelle (un étudiant par équipe) sur MonFortail. Vous devue ne suitere votre équipe portant. In mente non équipe que MonFortail (vous deux en équipe le votre équipe portant. In mente non équipe que MonFortail (vous deux en équipe deven étre des l'expires deux en équipe vous évent de l'expire que MonFortail (vous deux en équipe avent en équipe que MonFortail (vous deux en équipe deven étre deux en équipe vous étre deux en équipe vous étre deux en équipe avent en équipe vous étre deux en équipe vous en équipe vous en équipe vous étre deux en équipe vous étre deux en équipe vous en équipe vous étre deux en équipe vous équipe en équipe vous équipe vous équipe vous étre deux en équipe vous étre deux en équipe vous équipe vous équipe vous étre deux en équipe vous équipe vous équipe vous équipe vous équipe vous équ
- Si vous "empruntez" des idées, méthodes, démarches ou autres, merci d'indiquer vos sources dans le rapport.
- Il vous est fortement suggéré d'argumenter et/ou justifier vos réponses.
- Après la date de remise, vous avez jusqu'à une semaine pour remettre votre travail avec une pénalité de 20%. Au delà le travail vaut 0.
- Vous âtes libres d'utiliser les librairies telles que Numpy pour Python. Toutefois à moins d'être explicitement autorisées, vous ne devez pas utiliser des implémentations pré-existantes des algorithmes demandés, vous devez les implémenter par vous même.
- si vous avez des questions concernant le travail, merci de passer par le Forum, en posant clairement vos questions.

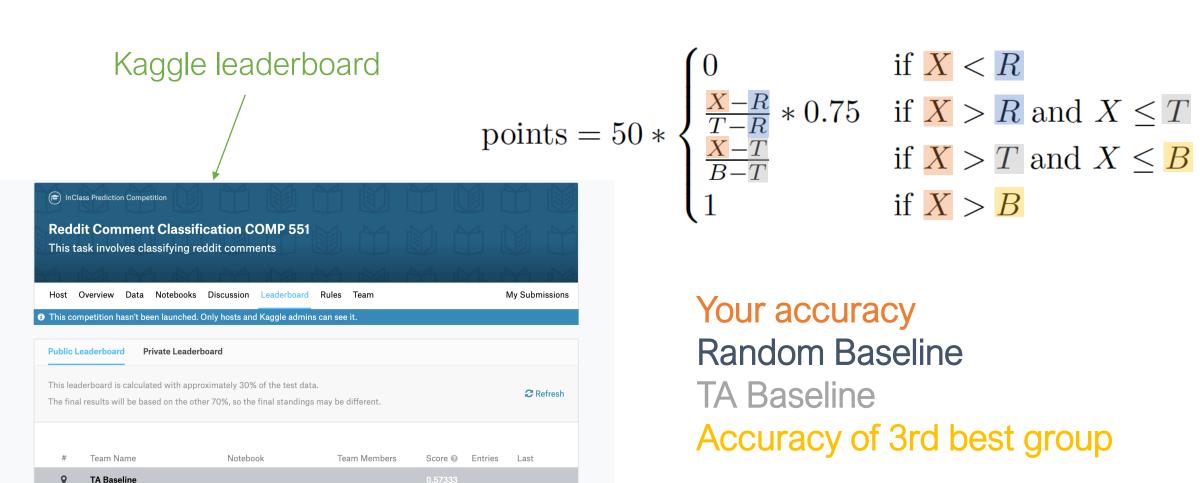
Background

In this mini-project you will develop models to analyze text from the website Reddit (https://www.raddit.com/), a popular social media forum where users post and comment on content in different themed communities, or subreddits. The goal of this project is to develop a supervised classification model that can predict what community a comment came from. You will be competing with other groups to achieve the best accuracy in a competition for this prediction task. However, your

1

MiniProject 2

Random Baseline



Steps to solving a supervised learning problem

1. Decide what the input-output pairs are.

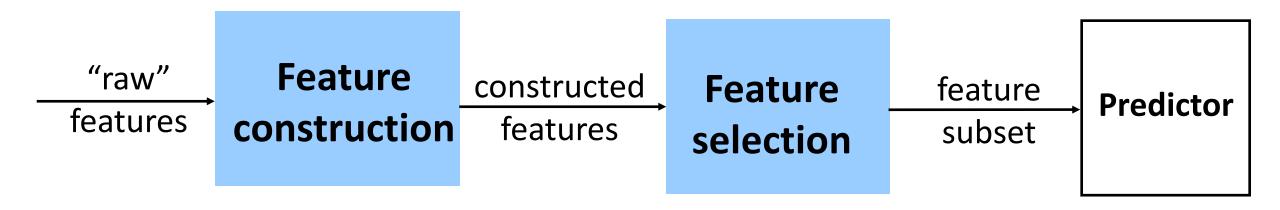
With a focus on feature extraction for language problems!

- 2. Decide how to encode inputs and outputs.
 - This defines the input space X and output space Y.
- 3. Choose a class of hypotheses / representations H.
 - E.g. linear functions.
- 4. Choose an error function (cost function) to define best hypothesis.
 - E.g. Least-mean squares.
- 5. Choose an algorithm for searching through space of hypotheses.

Today: deciding on what the inputs are

So far: we have been focusing on this

Feature extraction steps



A few strategies

- Use domain knowledge to construct "ad hoc" features.
- Normalization across different features, e.g. centering and scaling with $x_i = (x'_i \mu_i) / \sigma_i$.
- <u>Normalization</u> across different data <u>instances</u>, e.g. counts/histogram of pixel colors.
- Non-linear expansions when first order interactions are not enough for good results, e.g. products x_1x_2 , x_1x_3 , etc.
- Other functions of features (e.g. sin, cos, log, exponential etc.)
- Regularization (lasso, ridge).

Feature construction

Why do we do feature construction?

- Increase predictor performance.
- Reduce time / memory requirements.
- Improve interpretability.

But: Don't lose important information!

Problem: we may end up with lots of possibly irrelevant, noisy, redundant features. (Here, "noisy" is in the sense that it can lead the predictor astray.)

Scikit-learn et exemple

http://scikit-learn.org/stable/modules/classes.html

• implementing-a-naive-bayes-classifier-for-text-categorization

• Help/Questions : Amar Ali-Bey amar.ali-bey.1@ulaval.ca

Applications with lots of features

- Any kind of task involving images or videos object recognition, face recognition. Lots of pixels!
- Classifying from gene expression data. Lots of different genes!
 - Number of data examples: 100
 - Number of variables: 6000 to 60,000
- Natural language processing tasks. Lots of possible words!

Features for modelling natural language

- Words
- TF-IDF
- N-grams
- Syntactic features
- Word embeddings (not in this lecture...)
- Useful Python package for implementing these: http://www.nltk.org/

Words

- Binary (present or absent)
- Absolute frequency
 - i.e., raw count
- Relative frequency
 - i.e., proportion
 - document length

Document 1

The quick brown fox jumped over the lazy dog's back.

Document 2

Now is the time for all good men to come to the aid of their party. Term _______

aid	0	1
all	0	1
back	1	0
brown	1	0
come	0	1
dog	1	0
fox	1	0
good	0	1
jump	1	0
lazy	1	0
men	0	1
now	0	1
over	1	0
party	0	1
quick	1	0
their	0	1
time	0	1

Stopword List

for	
is	
of	
the	
to	

Multinomial vs Bernoulli Naïve Bayes

- Note that using binary vs. count features can have implications for your model!
- In Lecture 5 we discussed the Bernoulli (i.e., binary) Naïve Bayes:

$$P(\mathbf{x}|y=k) = \prod_{j=1}^{m} \theta_{j,k}^{x_j} (1-\theta_{j,k})^{(1-x_j)} \qquad \text{Bernoulli}$$
 distribution

- Assumes the features are binary counts.
- But we can also have a Multinomial Naïve Bayes:

$$P(\mathbf{x}|y=k) = \frac{(\sum_{j=1}^{m} x_j)!}{\prod_{j=1}^{m} x_j!} \prod_{\substack{j=1 \ \text{ounts.}}}^{m} \theta_{j,k}^{x_j}$$
 Multinomial distribution

Homework: what is the maximum likelihood estimate for the multinomial Naïve Bayes?

More options for words

Stopwords

- Common words like "the", "of", "about" are unlikely to be informative about the contents of a document.
- Standard practice to remove them, though they can be useful (e.g., for authorship identification)

Lemmatization

- Inflectional morphology: changes to a word required by the grammar of a language
 - e.g., "perplexing" "perplexed" "perplexes"
 - (Much worse in languages other than English, Chinese, Vietnamese)
- Lemmatize to recover the canonical form; e.g., "perplex"

TF*IDF (Salton, 1988)

- Term Frequency Times Inverse Document Frequency
- A term is important/indicative of a document if it:
 - 1. Appears many times in the document
 - 2. Is a relative rare word overall
- TF is usually just the count of the word
- IDF is a little more complicated:
 - $IDF(t, Corpus) = \log \frac{\#(Docs in Corpus)}{\#(Docs with term t) + 1}$
 - Can use a separate large training corpus for this
- Originally designed for document retrieval

TF-IDF (Wiki)

• https://fr.wikipedia.org/wiki/TF-IDF

N-grams

- Use sequences of words, instead of individual words
- e.g., ... quick brown fox jumped ...
 - Unigrams (i.e. words)
 - quick, brown, fox, jumped
 - Bigrams
 - quick_brown, brown_fox, fox_jumped
 - Trigrams
 - quick_brown_fox, brown_fox_jumped
- Usually stop at N <= 3, unless you have lots and lots of data

Rich linguistic features

Syntactic

- Extract features from a parse tree of a sentence
- [SUBJ The chicken] [VERB crossed] [OBJ the road].

Semantic

- e.g., Extract the semantic roles in a sentence
- [AGENT The chicken] [VERB crossed] [LOC the road].
- e.g., Features are synonym clusters ("chicken" and "fowl" are the same feature) → WordNet
- **Trade-off**: Rich, descriptive features might be more discriminative, but are hard (expensive, noisy) to get!

Autres liens

- https://medium.com/@RareLoot/basics-of-data-extraction-of-reddit-threads-using-python-c96854c41344
- https://praw.readthedocs.io/en/latest/tutorials/comments.html
- https://towardsdatascience.com/implementing-a-naive-bayes-classifier-for-text-categorization-in-five-steps-f9192cdd54c3
- https://www.learndatasci.com/tutorials/sentiment-analysis-reddit-headlines-pythons-nltk/